

Metody badań w finansach

Modele dla danych panelowych (modele podstawowe, model efektów stałych i losowych)



Plan na dziś

Modele dla danych panelowych

- Modele podstawowe
- Model efektów stałych
- Model efektów losowych
- Wybór modelu

Typy danych – przypomnienie

Szereg czasowy

Rok	Inflacja (%)
2020	2.25
2021	2.18
2022	2.5
2023	3.26
2024	3.15
2025	3.03

Jedna jednostka w wielu okresach
(np. latach)

$$t = 1, 2, \dots, T$$

Dane przekrojowe

Firma	Zadłużenie
Firma_1	0.32
Firma_2	0.65
Firma_3	0.54
Firma_4	0.58
Firma_5	0.31

Wiele jednostek w jednym okresie

$$i = 1, 2, \dots, N$$

Struktura danych panelowych

Szereg czasowy



Dane przekrojowe



Dane panelowe

(i, t)
↓ ↓
jednostka czas

wiele
jednostek

różne kraje

wiele okresów

Firma	Kraj	Rok	Wskaźnik X
A	Polska	2021	51.36
A	Polska	2022	52.19
A	Polska	2023	54.74
B	Niemcy	2021	48.91
B	Niemcy	2022	50.19
B	Niemcy	2023	52.94
C	Czechy	2021	51.88
C	Czechy	2022	52.79
C	Czechy	2023	54.66

Dane panelowe – dlaczego warto?

Dzięki danym panelowym można badać zarówno różnice między jednostkami, jak i to, jak każda z nich zmienia się w czasie.

- Kontrola nieobserwowalnej heterogeniczności (stałe w czasie cechy jednostek lub cechy, które są trudne lub niemożliwe do bezpośredniego pomiaru) → **ograniczamy problem pominiętych zmiennych**
- Większa liczba obserwacji (liczba obserwacji: $N \times T$)
- Możliwość analizy dynamiki
- Oddzielenie efektów:
 - wewnątrz jednostki (within effect)
 - między jednostkami (between effect)

Dane panelowe – na co zwrócić uwagę?

Budowa panelu

Panele często budujemy łącząc różne bazy danych, dlatego w szczególności trzeba zweryfikować:

- Zgodność w latach
- Dostępność danych w badanych latach
- Zgodność w separatorach



Panel zbilansowany: każda jednostka ma obserwacje dla wszystkich okresów
Panel niezbilansowany: braki obserwacji

Wyzwania

- Bardziej złożona estymacja
- Problemy z autokorelacją i heteroskedastycznością
- Brak estymacji zmiennych stałych w FE (o tym później)

Pooled OLS

Założenia

- Jest to model, który ignoruje panelową strukturę danych i traktuje wszystkie obserwacje jako niezależne.
- Łączy (agreguje) dane ze wszystkich jednostek i okresów czasu, estymując jeden wspólny zestaw współczynników.
- Jest to po prostu klasyczna regresja liniowa, więc powinny być spełnione wszystkie założenia twierdzenia Gaussa-Markova

Postać modelu

$$y_{it} = \beta_0 + \beta_1 \times x_{1,it} + \beta_2 \times x_{2,it} + \dots + e_{it}$$

↑
Stała w modelu

↖ ↗
 β_k współczynnik dla zmiennej $x_{k,it}$

Pooled OLS

Wady modelu

- Model nie wykorzystuje informacji wynikających ze zróżnicowania międzygrupowego i w czasie.
- Model zakłada, że obserwacje w ramach jednej grupy są niezależne → najczęściej tak nie jest, więc może to zaburzać estymację
- Jeśli w składniku losowym występuje nieobserwowalny efekt indywidualny i jest on skorelowany z regresorami, to estymator OLS będzie **obciążony**.

Postać modelu

$$y_{it} = \beta_0 + \beta_1 \times x_{1,it} + \beta_2 \times x_{2,it} + \dots + e_{it}$$

↑
Stała w modelu

↖ ↗
 β_k współczynnik dla zmiennej $x_{k,it}$

Model efektów stałych

Fixed effect (FE)

Założenia

- Model efektów stałych zakłada, że każda jednostka (np. bank, firma, kraj) ma własny, **nieobserwowalny efekt indywidualny**, który:
 - jest **stały w czasie**,
 - może być **skorelowany ze zmiennymi objaśniającymi**.

Postać modelu

$$y_{it} = \alpha_i + \beta_1 \times x_{1,it} + \beta_2 \times x_{2,it} + \dots + e_{it}$$



Stały w czasie efekt indywidualny dla obserwacji i (banku, kraju, itp..)

Model efektów stałych – przykład

Giannopoulos, G., Kihle Fagernes, R. V., Elmarzouky, M., & Afzal Hossain, K. A. B. M. (2022). **The ESG Disclosure and the Financial Performance of Norwegian Listed Firms.** Journal of Risk and Financial Management, 15(6), 237. <https://doi.org/10.3390/jrfm15060237>

Estymowane modele:

$$ROA_{it} = \beta_0 + \beta_1 ESG_{it} + \beta_2 SIZE_{it} + \beta_3 LEV_{it} + \varepsilon$$

$$Tq_{it} = \beta_0 + \beta_1 ESG_{it} + \beta_2 SIZE_{it} + \beta_3 LEV_{it} + \varepsilon$$

Abstrakt

(...) This paper investigates the effects of ESG initiatives on the financial performance of **Norwegian listed companies from 2010 to 2019**. ESG is measured through the Thomson Reuters Eikon ESG disclosure score and financial performance through ROA and Tobin's Q. To the best of our knowledge, this is the first time this relationship has been investigated in Norway. **Using panel data regression analysis** and two proxies for the dependent variable (financial performance), the results of this study are mixed. In particular, findings suggest a strong significant relationship between ESG initiatives and financial performance. More specifically, the regression model, with ROA as the dependent variable, suggests that ESG initiatives have a clear negative impact. On the other hand, the variable Tobin's Q increases when ESG increases. This could be explained by the different horizons of the measures and other factors affecting the business environment.

Uzasadnienie wyboru metody

To decide whether to use a fixed effect or a random effect model when conducting the regression, the Hausman test is used. The aim is to test the null hypothesis; therefore, the random effects model should be used. The results from this test, using the dependent variables ROA and Tobin's Q, are presented in Table 5 below. The test shows that the p-value is significant at a 5% level for the ROA and insignificant at 5% for Tobin's Q. The null hypothesis is thus rejected for the latter. **Furthermore, this implies that a fixed effects test should be used when ROA is the dependent variable**, and a random effect test should be used with Tobin's Q as the dependent variable.

Model efektów stałych

Transformacja within

1. Równanie podstawowe

$$y_{it} = \beta_0 + \beta_1 \times x_{1,it} + \beta_2 \times x_{2,it} + \dots + e_{it}$$

2. Wyznaczenie średnich w badanym okresie

$$\bar{y}_i = \beta_0 + \beta_1 \times \bar{x}_{1,i} + \beta_2 \times \bar{x}_{2,i} + \dots + \bar{e}_i$$

3. Odjęcie średnich wartości od równania podstawowego

$$(y_{it} - \bar{y}_i) = (\beta_1 \times x_{1,it} - \beta_1 \times \bar{x}_{1,i}) + (\beta_2 \times x_{2,it} - \beta_2 \times \bar{x}_{2,i}) + \dots + (e_{it} - \bar{e}_i)$$

Model efektów stałych

Transformacja within

Jak działa model?

- Poprzez transformację within stałe w czasie cechy jednostki są „wycięte” z modelu.
- Estymacja opiera się wyłącznie na zmienności wewnątrz jednostki.

Interpretacja parametrów

β mierzy wpływ zmiany x w tej samej jednostce/grupie na zmianę y .

Model nie uwzględnia zmian pomiędzy grupami.

Model efektów stałych

Transformacja between

Równanie średnich

$$\bar{y}_i = \beta_0 + \beta_1 \times \bar{x}_{1,i} + \beta_2 \times \bar{x}_{2,i} + \dots + \bar{e}_i$$

Interpretacja parametrów

Mierzy wpływ zmiany pomiędzy grupami na y .

Model nie uwzględnia zmian wewnątrz grupy.

Model efektów losowych

Random effect (RE)

Założenia

- Nieobserwowalne efekty indywidualne nie są skorelowane ze zmiennymi objaśniającymi.
- Efekty indywidualne nie są skorelowane z błędami.
- $E(v_i, v_j) = 0, \quad i \neq j$
- Efekt jednostkowy v_i traktowany jest jako składnik losowy, a nie stały parametr do oszacowania.

Postać modelu

$$y_{it} = \beta_0 + \beta_1 \times x_{1,it} + \beta_2 \times x_{2,it} + \dots + e_{it}$$



$$e_{it} = v_i + \varepsilon_{it}$$



Efekt indywidualny wynikający ze zmian losowych i nie zmieniający się w czasie

Model efektów losowych – przykład

Athanasoglou, P. P., Delis, M., & Staikouras, C. (2006). **Determinants of bank profitability in the South Eastern European region** (SSRN Scholarly Paper No. 4163741). Social Science Research Network. <https://doi.org/10.2139/ssrn.4163741>

Estymowane modele:

To test the relationship between bank profitability and the bank-specific, industry-related and macroeconomic determinants described above, we estimate a linear regression model of the following form:¹⁷

$$\Pi_{its} = c + \sum_{j=1}^J \beta_j X_{its}^j + \sum_{l=1}^L \beta_l X_{ts}^l + \sum_{m=1}^M \beta_m X_{ts}^m + \varepsilon_{its} \quad (1)$$
$$\varepsilon_{its} = v_i + u_{its},$$

where Π_{its} is the profitability of bank i at time t for country s , with $i = 1, \dots, N$; $t = 1, \dots, T$; $s = 1, \dots, S$, c is a constant term, the X s are explanatory variables (grouped into bank-specific, industry-related and macroeconomic determinants, j , l and m respectively) and ε_{its} is the disturbance, with v_i capturing the unobserved bank-specific effect and u_{its} the idiosyncratic error. This is a one-way error component regression model, where $v_i \sim \text{IIN}(0, \sigma_v^2)$ and independent of $u_{its} \sim \text{IIN}(0, \sigma_u^2)$.

Abstrakt

The aim of this study is to examine the profitability behaviour of bank-specific, industry-related and macroeconomic determinants, using an **unbalanced panel dataset of South Eastern European (SEE) credit institutions over the period 1998-2002**. The estimation results indicate that, with the exception of liquidity, all bank-specific determinants significantly affect bank profitability in the anticipated way. A key result is that the effect of concentration is positive, which provides evidence in support of the structure-conduct-performance hypothesis, while at the same time some relevance of the efficient-structure hypothesis cannot be rejected. In contrast, a positive relationship between banking reform and profitability was not identified, whilst the picture regarding the macroeconomic determinants is mixed. The paper concludes with some remarks on the practicality and implementability of the findings.

Uzasadnienie wyboru metody

We apply the least squares methods of fixed effects (FE) and random effects (RE) models. Under a FE model the v_i 's are considered fixed parameters to be estimated, while under a RE model the v_i 's are assumed to be random and the estimation method is generalized least squares (GLS). There is strong evidence that our specification follows a RE model as the Hausman test indicates (the relevant p-values are 0.243 and 0.144 for the ROA and ROE equations respectively).

Model efektów losowych

Random effect (RE)

Korzyści

- Model znajduje zastosowanie we wnioskowaniu o populacji na podstawie próby.
- Pozwala uwzględnić wśród zmiennych objaśniających zmienne stałe w czasie.
- Model RE łączy dwa źródła zmienności:
 - Zmienność wewnątrz jednostki (zmiany w czasie)
 - Zmienność między jednostkami (różnice średnich)
 - Parametr β jest zatem „średnią ważoną” efektu within i between.

Przy spełnionych założeniach estymator RE jest bardziej efektywny niż estymator FE.

FE czy RE? Wybór modelu

Test Hausmana

Test Hausmana porównuje FE i RE.

H_0 : brak korelacji efektu jednostkowego z regresorami (oba estymatory dają podobne wyniki, są zgodne, ale RE jest zgodny i efektywny). Odrzucenie H_0 sugeruje wybór estymatora FE, estymator RE nie jest zgodny.


	Estymator RE	Estymator FE
$H_0: Cov(u_i, x_i) = 0$	zgodny, efektywny	zgodny, nieefektywny
$H_1: Cov(u_i, x_i) \neq 0$	niezgodny	zgodny

Źródło: Mycielski, J. (2009). *Ekonometria*. UW WNE, s. 324

FE czy RE? Wybór modelu

Wybór modelu opieraj na:

- Testach statystycznych (Hausman)
- Teorii ekonomicznej, zadaj sobie pytania:
 - Czy realistyczne jest założenie, że nieobserwowalne cechy jednostek nie wpływają na zmienne objaśniające?
 - Czy jednostki są losową próbą z większej populacji?
 - Czy interesują Cię różnice między jednostkami czy zmiany w czasie?



Podstawowe modele panelowe w R

```
model <- plm(y ~ zmienne objaśniające,  
             data = źródło danych,  
             model = typ modelu) → „pooling”  
                                   „between”  
                                   „within”  
                                   „random”
```

W komendzie plm jest jeszcze 4 argument - efekty.

Effects = „individual” (opcja domyślna), effects = „time”, effects = „twoways”

Pooled OLS

```
Call:
lm(formula = ROA ~ Loan_to_Assets + Leverage + Interest_Rate +
    Size + GDP_Growth, data = pdata)
```

```
Residuals:
    Min       1Q   Median       3Q      Max
-0.025341 -0.009326 -0.003130  0.007921  0.069211
```

```
Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)   0.1181603  0.0341222   3.463 0.000673 ***
Loan_to_Assets 0.0166203  0.0061183   2.716 0.007264 **
Leverage       0.0001935  0.0005416   0.357 0.721373
Interest_Rate  0.0013755  0.0009468   1.453 0.148093
Size          -0.0136691  0.0039765  -3.438 0.000734 ***
GDP_Growth    -0.0003247  0.0007519  -0.432 0.666425
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
Residual standard error: 0.01439 on 174 degrees of freedom
Multiple R-squared:  0.3371,    Adjusted R-squared:  0.318
F-statistic: 17.7 on 5 and 174 DF, p-value: 3.693e-14
```

```
Call:
plm(formula = ROA ~ Loan_to_Assets + Leverage + Interest_Rate +
    Size + GDP_Growth, data = pdata, model = "pooling")
```

```
Balanced Panel: n = 20, T = 9, N = 180
```

```
Residuals:
    Min.    1st Qu.    Median    3rd Qu.    Max.
-0.0253411 -0.0093256 -0.0031305  0.0079211  0.0692111
```

```
Coefficients:
              Estimate Std. Error t-value Pr(>|t|)
(Intercept)   0.11816032  0.03412220   3.4629 0.0006727 ***
Loan_to_Assets 0.01662031  0.00611833   2.7165 0.0072644 **
Leverage       0.00019348  0.00054165   0.3572 0.7213726
Interest_Rate  0.00137551  0.00094683   1.4528 0.1480932
Size          -0.01366913  0.00397646  -3.4375 0.0007345 ***
GDP_Growth    -0.00032466  0.00075188  -0.4318 0.6664246
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
Total Sum of Squares:    0.054328
Residual Sum of Squares: 0.036015
R-Squared:                0.33709
Adj. R-Squared: 0.31804
F-statistic: 17.6961 on 5 and 174 DF, p-value: 3.693e-14
```

```
Call:
plm(formula = ROA ~ Loan_to_Assets + Leverage + Interest_Rate +
      Size + GDP_Growth, data = pdata, model = "within")
```

Balanced Panel: n = 20, T = 9, N = 180

Residuals:

Min.	1st Qu.	Median	3rd Qu.	Max.
-0.0284655	-0.0091100	-0.0019186	0.0079923	0.0642583

Coefficients:

	Estimate	Std. Error	t-value	Pr(> t)	
Loan_to_Assets	0.01573780	0.00660033	2.3844	0.018316	*
Leverage	0.00038126	0.00057246	0.6660	0.506399	
Interest_Rate	0.00155124	0.00103614	1.4971	0.136393	
Size	-0.01427702	0.00430853	-3.3137	0.001146	**
GDP_Growth	-0.00023823	0.00079989	-0.2978	0.766231	

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Total Sum of Squares: 0.050381

Residual Sum of Squares: 0.032973

R-Squared: 0.34554

Adj. R-Squared: 0.2442

F-statistic: 16.3669 on 5 and 155 DF, p-value: 5.9606e-13

Informacja czy panel jest
zbilansowany, liczba
grup/jednostek, liczba lat,
liczba obserwacji

Typ modelu

Dla każdego parametru testujemy:
 $H_0: \beta_j = 0; H_1: \beta_j \neq 0$

p-value > 0.05 → brak
istotności na poziomie 5%
Zmienna **nie jest istotna**
statystycznie.

p-value < 0.05 → odrzucamy H_0
Zmienna jest **statystycznie**
istotna.

Statystyka F:
zmienne objaśniające są łącznie istotne
(16.52; p-value = 0 < 0,05; odrzucamy hipotezę
zerową o łącznej nieistotności zmiennych).
Model jako całość jest statystycznie istotny.

$$e_{it} = v_i + \varepsilon_{it}$$

```
Call:
plm(formula = ROA ~ Loan_to_Assets + Leverage + Interest_Rate +
      Size + GDP_Growth, data = pdata, model = "random")
```

Balanced Panel: n = 20, T = 9, N = 180

Effects:

	var	std.dev	share
idiosyncratic	0.0002127	0.0145852	1
individual	0.0000000	0.0000000	0

theta: 0

Residuals:

Min.	1st Qu.	Median	3rd Qu.	Max.
-0.0253411	-0.0093256	-0.0031305	0.0079211	0.0692111

Coefficients:

	Estimate	Std. Error	z-value	Pr(> z)
(Intercept)	0.11816032	0.03412220	3.4629	0.0005345 ***
Loan_to_Assets	0.01662031	0.00611833	2.7165	0.0065980 **
Leverage	0.00019348	0.00054165	0.3572	0.7209397
Interest_Rate	0.00137551	0.00094683	1.4528	0.1462922
Size	-0.01366913	0.00397646	-3.4375	0.0005871 ***
GDP_Growth	-0.00032466	0.00075188	-0.4318	0.6658900

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Total Sum of Squares: 0.054328

Residual Sum of Squares: 0.036015

R-Squared: 0.33709

Adj. R-Squared: 0.31804

Chisq: 88.4804 on 5 DF, p-value: < 2.22e-16

Typ modelu

Pojawia się **stała** w modelu i jest statystycznie istotna.

Podobnie jak w modelu FE, zmienne Loan_to_Assets i Size są statystycznie istotne.

Model jako całość jest statystycznie istotny.

Schemat działania

R:
`pFtest(model_within,
n, model_pooled)`

Poolability test [wybór między FE a Pooled]

$$H_0: \alpha_1 = \alpha_2 = \dots = \alpha_N$$

Brak statystycznej istotności różnic między badanymi jednostkami

p-value > 0.05
brak podstaw do odrzucenia H_0

Pooled OLS

p-value < 0.05
odrzucaamy H_0

FE

Schemat działania

R:
`phtest(model_within,
n, model_random)`

Test Hausmana [wybór między FE a RE]

H_0 : brak korelacji między efektami indywidualnymi a zmiennymi objaśniającymi

H_0 : zarówno FE jak i RE są zgodne

H_1 : RE nie jest zgodny

p-value > 0.05
brak podstaw do odrzucenia H_0

RE

p-value < 0.05
odrzucaamy H_0

FE

Problemy w modelowaniu

Heteroskedastyczność

Wariancja składnika losowego nie jest stała

Test Breuscha–Pagana

H_0 : wariancja jest stała (homoskedastyczność)

Jeśli zostanie wykryta heteroskedastyczność, można zastosować odporną macierz kowariancji.

R:
`bptest(model)`

Autokorelacja

Składniki losowe są zależne od siebie

Test Breuscha–Godfrey

H_0 : brak autokorelacji

R:
`pbgttest(model)`

Literatura

- Kopczewska, K., Kopczewski, T., Wójcik, P. – Metody ilościowe w R Aplikacje ekonomiczne i finansowe
- Hanck, C., Arnold, M., Gerber, A., Schmelzer, M. – Introduction to Econometrics with R <https://www.econometrics-with-r.org/index.html>
- Mycielski, J. – Ekonometria
- https://cran.r-project.org/web/packages/plm/vignettes/A_plmPackage.html
- Wooldridge, J. M. – Econometric Analysis of Cross Section and Panel Data
- Baltagi, B. H. – Econometric Analysis of Panel Data

Przykładowe źródła informacji o modelach panelowych w R:

- *Dobra, M.* – Prelude to Econometrics Using R; <https://bookdown.org/mattdobra/Prelude/>
- *Colonescu, C.* – Principles of Econometrics with R; <https://bookdown.org/ccolonescu/RPoE4/>